Inteligencja obliczeniowa i jej zastosowania

Laboratorum cz. IV, nr 1-2

Autorzy:

Joanna Piątek, nr indeksu: 199966 Agnieszka Wątrucka, nr indeksu: 200016 Grupa: Środa, 15:15

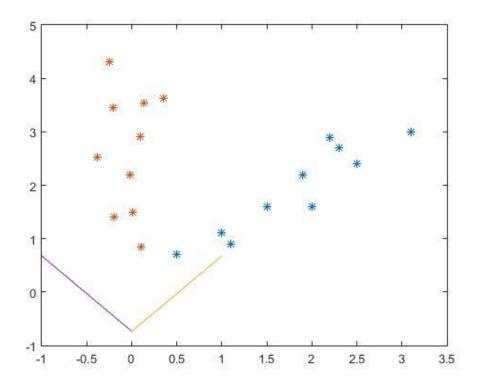
7 czerwca 2017

Prowadzący: prof. dr hab. inż. Rafał Zdunek

1 Zadanie nr 1

W ćwiczeniu nr 1 za zadanie była implementacja metody PCA w środowisku Matlab, wyznaczenie składowych głównych i wektora cech oraz wskazać na rysunku punkty obserwacji oraz wyznaczone wielkości.

1.1 Wyniki



Rysunek 1: Wykres zawierający wartości własne oraz wyznaczone wektory wartości własnych

Na wykresie zostały przedstawione punkty obserwacji i wektory wartości własnych wyznaczone za pomocą zaimplementowanej metody PCA.

1.2 Implementacja

Rysunek 2: Implementacja algorytmu PCA i rysowanie wykresu dla zadanych danych

2 Zadanie 2

2.1 Implementacja główna

```
classes count = 5;
% Wczytywanie zdjec dla wybranej liczy klas
images arrays = getAllImages(classes count);
J = [4, 10, 20, 30];
iterations = 10;
\% Wektor zawierajacy klasy kolejnych obrazow
images classes = [];
for i = 1: classes\_count
        images classes = [images classes; ones(10,1).*i];
\mathbf{end}
\% Petla glowna
for j val = 1:4
        grouping results = zeros([iterations 4]);
        classification results = zeros([iterations 4]);
        for i = 1 : iterations
                \% Redukcja wymiarow
                [V, pca images arrays, D] = myPCA(images arrays', J(j val));
                % Grupowanie za pomoca k-srednich
                 g result = getGroupingResults(
```

```
images_arrays, pca_images_arrays, classes_count,
images_classes);
grouping_results(i,:) = g_result;

% Klasyfikacja z uzyciem k-NN
c_result = getClassificationResults(
images_arrays, pca_images_arrays, classes_count,
images_classes);
classification_results(i,:) = c_result;
end

% Zapis wynikow do plikow
(...)
end
```

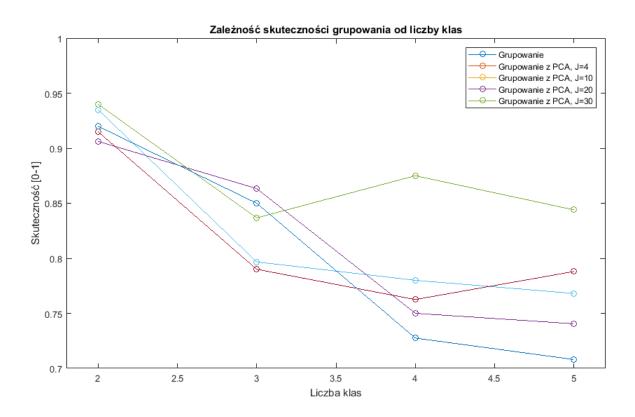
2.2 Implementacja grupowania

2.3 Implementacja klasyfikacji

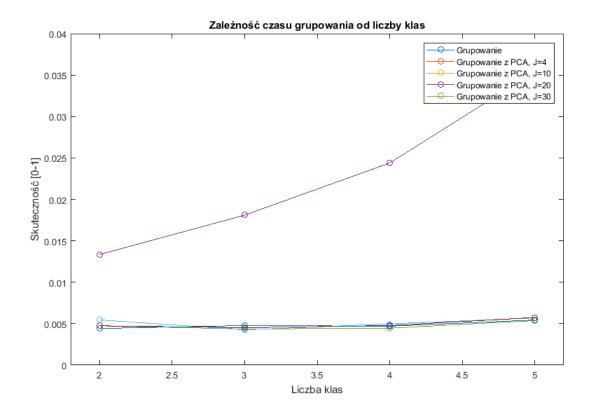
```
function result = getClassificationResults(images arrays, pca images arrays,
 classes count, images classes)
        \% Uruchomienie klasyfikacji k-NN,
        % Zapis wynikow i czasu trwania
        tic:
        model = fitcknn(images arrays, images classes);
        cv model = crossval(model, 'KFold', classes count);
        default\_time = toc;
        tic;
        model_pca = fitcknn(pca_images_arrays', images_classes);
        cv model pca = crossval (model pca, 'KFold', classes count);
        pca time = toc;
        \% Obliczenie skutecznosci grupowania
        cv model loss = kfoldLoss(cv_model);
        default \ acc = 1 - cv \ model \ loss;
        cv_model_pca_loss = kfoldLoss(cv_model_pca);
        pca \ acc = 1 - cv \ model \ pca \ loss;
        result = [default acc, pca acc, default time, pca time];
```

2.4 Wyniki

2.4.1 Grupowanie

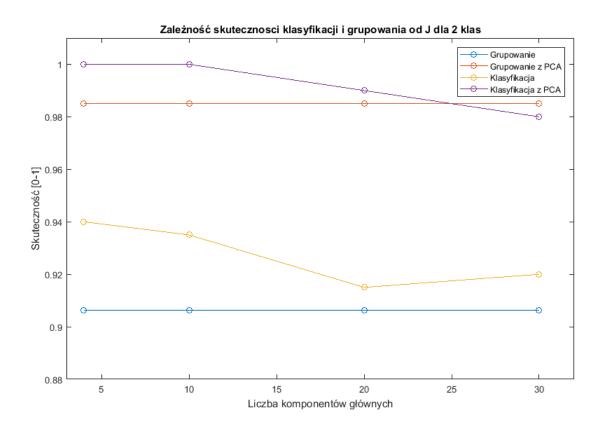


Rysunek 3: Skuteczność grupowania dla wymiarów pełnych i zredukowanych

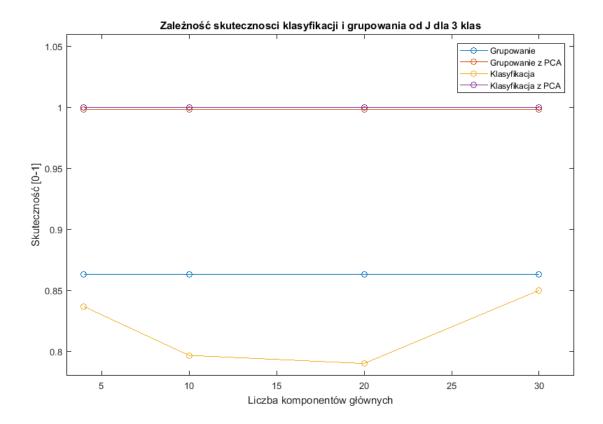


Rysunek 4: Czas grupowania dla wymiarów pełnych i zredukowanych

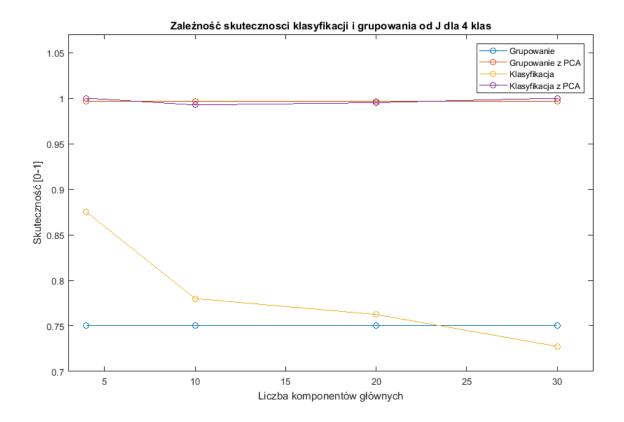
2.4.2 Porównanie klasyfikacji i grupowania



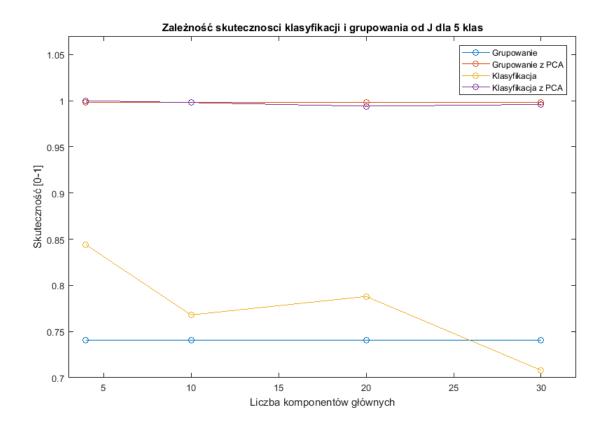
Rysunek 5: Skuteczność grupowania i klasyfikacji dla 2 klas



Rysunek 6: Skuteczność grupowania i klasyfikacji dla 3 klas



Rysunek 7: Skuteczność grupowania i klasyfikacji dla 4 klas



Rysunek 8: Skuteczność grupowania i klasyfikacji dla 5 klas